Аналитический отчет о работе спортивного магазина

Вступление.

Магазин специализируется на международной продаже спортивных товаров. Заказчика интересует анализ его продаж в стране 32.

Целью анализа является определение успешности проведенной маркетинговой кампании, определение групп покупателей по схожим признакам (по социально-демографическим признакам и данных об их покупках) и построение модели, отражающей склонность клиента города 1188 к покупке.

Исследование и предобработка данных.

Компанией были предоставлены следующие данные, которые хранятся в базе данных.

1. Зашифрованные персональные данные клиентов.
2. Данные с персональными коэффициентами клиентов.
3. Данные о покупках.
4. Сжатый файл с утерянными данными о клиентах.
5. Два файла txt с информацией о клиентах, участвовавших в маркетинговой кампании.

Первоначально были выгружены данные из базы данных только по стране 32. Для восстановления утерянных данных о поле клиента было построено 3 модели: логистическая модель, модель на основе деревьев и модель случайного леса. Чтобы определить модель для восстановления данных для каждой модели были рассчитаны их ошибки, а также кросс-валидация.

Оценка ошибки в каждой модели показала практически одинаковые результаты. Учтем тот факт, что модель случайного леса при кросс-валидации дала чуть меньшую ошибку, поэтому используем ее для восстановления утерянных данных о поле клиентов.

```
Логистическая модель
Обычный прогноз: MSE = 0.61, MAE = 0.37
Итоги при кросс-валидации: MSE = 0.65, MAE = 0.43

Модель на основе деревьев
Обычный прогноз: MSE = 0.61, MAE = 0.37
Итоги при кросс-валидации: MSE = 0.65, MAE = 0.44
Кросс-валидация при заданной глубине: MSE = 0.65, MAE = 0.43

Случайный лес
Обычный прогноз: MSE = 0.61, MAE = 0.37
Кросс-валидация при заданной глубине: MSE = 0.65, MAE = 0.42
```

После этого все данные о клиентах и их покупках были объединены в один общий датафрейм о покупателях и их покупках (далее – датафрейм), который содержит 780 110 строк

A/B-тестирование

Моделирование.

A/B-тестирование проводилось с 5-го по 16-й день. Суть заключалась в предоставлении персональной скидки 5 000 клиентам через e-mail-рассылку (тестовая группа), а также была отобрана группа людей со схожими социально-демографическим признакам и покупками, которые не получили предложения о скидке (контрольная группа).

Согласно вводным данным по проведенной маркетинговой кампании из датафрейма были сформированы 2 группы: контрольная (19 876 клиента) и тестовая (24 959 клиентов).

Основной метрикой при анализе успешности маркетинговой кампании было соотношение количества купивших по скидке к общему числу. В качестве *вспомогательной* – средняя цена товара.

Анализ результатов.

Были получены следующие результаты A/B-тестирования.

	Контрольная группа	Тестовая группа	Контрольная – тестовая
Соотношение количества купивших по скидке к общему числу, %	30,14	30,05	0,09 п. п.
Средняя цена товара	5 590,45	5 312,00	278,45
Размер группы	19 876	24 959	

Для определения значимости результатов A/B-тестов, был проведен статистический тест.

Тест Левена указал на равенство дисперсий выборки, а тест Шапиро-Уилка показал, что распределение тестовой и контрольной выборки отличаются от нормального. Учитывая полученные факты, был проведен статистический t-test.

Рассматривались 2 гипотезы.

H_0: Разницы между соотношением количества купивших по скидке к общему числу покупателей контрольной и тестовой групп нет.

H_1: Разница между соотношением количества купивших по скидке к общему числу покупателей контрольной и тестовой групп есть.

Значения p-value при проведении t-test оказалось равным 0,848, что говорит о том, что доказательств значимой разницы между группами нет.

Рекомендации по улучшению модели.

Предоставление скидки через email-рассылку не повысила покупаемость товаров. Возможно, это говорит о том, что проведение акции таким образом не самый лучший способ. Стоит рассмотреть другие варианты привлечения клиентов, в том числе и предоставление персональной скидки. Например, воспользоваться смс-рассылкой на телефон или мессенджеры.

Кластеризация

Моделирование.

Датафрейм содержит, как количественные, так и категориальные переменные, поэтому для кластеризации данных был применен метод *KPrototypes*.

Как показал анализ, датафрейм содержит 23 109 уникальных названия товаров, 1 690 уникальных названия цветов. В тоже время отметим, что названия некоторых одинаковых товаров и цветов пишутся по-разному (например, синий и синие). Поэтому для товаров и цветов было сформировано 9 и 12 групп соответственно. Таким образом, в датафрейме появилось 2 дополнительных столбца.

Категория «пол товара» имеет 312 574 (или 40%) пропусков.

Используя столбец с категориями товаров, запишем в данный столбец новые данные.

```
'Женские товары': 0,
'Товары для девочек': 0,
'Мужские товары': 1,
'Товары для мальчиков': 1,
'Детские товары': 3,
'Спортивные товары': 4,
'Другие товары для спорта и отдыха': 4,
'Унисекс': 2,
'Другое': 5
```

Из полученного датафрейма удалим лишние данные: товар и цвет (заменили на группы), id и дату (не несет смысловой нагрузки), страна (работаем в рамках одной страны).

Данные для кластеризации выглядят так:

	gender	age	education	city	cost	product_sex	base_sale	personal_coef	product_group	color_group
0	0	36	среднее	1201	13599	0	1	0.5072	Женские товары	Разноцветный
1	0	36	среднее	1201	1499	5	0	0.5072	Другое	Зеленый
2	0	36	среднее	1201	4799	5	0	0.5072	Другое	Коричневый
3	0	35	среднее	1134	9199	3	0	0.5072	Детские товары	Разноцветный
4	0	35	среднее	1134	4999	5	0	0.5072	Другое	Светлый

Перед применением кластеризации метод KPrototypes подготовим данные: выделим и нормируем количественные данные, выделим категориальные данные. Отметим, что данные о поле, городе и поле продукта отнесем к категориальным.

Для определения количества кластеров, на которое необходимо разбить датафрейм воспользуемся методом локтя и методом силуэта.

Метод локтя

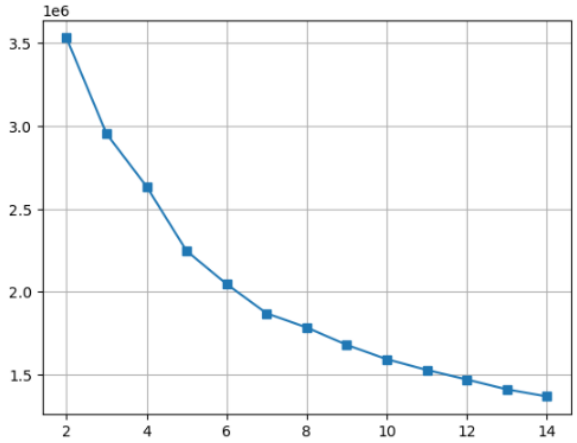

Метод силуэта

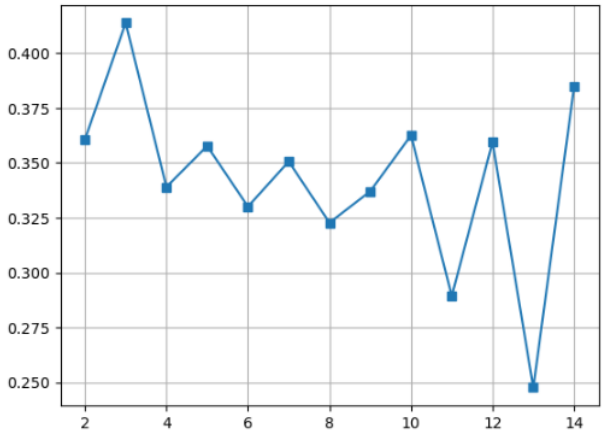

Отчетливого перегиба в методе локтя нет, но можно допустить, что значение существенно не снижается после 9-10. Метод силуэта также не дает четкого ответа, допустимо предположить, что число кластеров 10.

Таким образом, разобьем датафрейм на 10 кластеров.

Анализ результатов.

Рассмотрим особенности полученных кластеров.

cluster	age	cost	personal_coef	values
0	38.565648	1324.403965	0.465868	341589
1	37.659244	17124.319453	0.449811	30042
2	38.370829	10795.853032	0.449926	44867
3	38.303033	6594.509804	0.455510	110011
4	36.396958	26028.014697	0.447625	15649
5	38.801834	3722.430829	0.462309	225674
6	32.659218	326152.798883	0.433314	179
7	36.187669	117264.058266	0.442539	1476
8	36.780951	43438.149372	0.446903	6688
9	37.412961	70187.900381	0.442556	3935

cluster	education	product_group	color_group	gender	city	product_sex	base_sale	values
0	среднее	Другое	Разноцветный	1	1134	5	0	341589
1	среднее	Мужские товары	Разноцветный	1	1134	1	0	30042
2	среднее	Мужские товары	Разноцветный	1	1134	1	0	44867
3	среднее	Мужские товары	Разноцветный	1	1134	1	0	110011
4	среднее	Другое	Разноцветный	1	1134	5	0	15649
5	среднее	Мужские товары	Разноцветный	1	1134	1	0	225674
6	среднее	Другое	Разноцветный	1	1134	5	0	179
7	среднее	Другое	Разноцветный	1	1134	5	0	1476
8	среднее	Другое	Разноцветный	1	1134	5	0	6688
9	среднее	Другое	Другой цвет	1	1134	5	0	3935

Анализ результатов показывает, что категориальные переменные имеют практически одинаковое значение для всех кластеров. Это объясняется тем, что данные категории превалируют в датафрейме.

```
Доля каждой категории продукта в датафрейме.
Женские товары - 25.54%
Другое - 23.95%
Детские товары - 2.33%
Товары для девочек - 3.25%
Товары для мальчиков - 5.41%
Мужские товары - 34.62%
Спортивные товары - 0.97%
Другие товары для спорта и отдыха - 2.58%
Унисекс - 1.34%
```

```
Доля каждой категории цвета в датафрейме
Разноцветный - 28.56%
Зеленый - 4.38%
Коричневый - 6.22%
Светлый - 5.88%
Красный - 3.11%
Другой цвет - 15.38%
Черный - 21.55%
Синий - 6.89%
Серый - 4.81%
Желтый - 1.08%
Бордовый - 0.57%
Фиолетовый - 1.57%
```

Существенного различия в персональных коэффициентах между кластерами не наблюдается. Средний возраст покупателей кластеров колеблется в диапазоне 30-40 лет. Основной вклад в разбиение было оказано со стороны средней стоимости товаров.

Так самый немногочисленный кластер (179 покупателей) включает в себя самых молодых покупателей (около 32 дет) и самые дорогие покупки (средняя стоимость товаров – 326 152 единиц). Это кластер 6 в таблице.

Следующие три небольших кластера включают покупателей в возрасте 36-37 лет, которые также совершают достаточно дорогие покупки. Это кластеры 7, 8, 9 в таблице.

Самый большой кластер (341 589 покупателей) – это 38,5 летние мужчины, которые покупают в среднем самые дешевые товары (1 324 единиц). Это кластер 0 в таблице.

В тоже время стоит отметить, что еще 2 наиболее многочисленных кластера также содержат в основном 38-летних мужчин, которые покупаю в основном практически самые дешевые товары. Это кластеры 3 и 5 в таблице.

Оставшиеся 3 кластера отражают информацию о покупателях, которые совершают не сильно дорогие покупки и чем меньше возраст, тем дороже покупки.

Рекомендации по улучшению модели.

Предлагается основной акцент рекламных и маркетинговых кампаний делать на город 1134. С учетом того, что возрастная категория до 35 лет, более склонна к дорогим покупкам, то кампании для них должны быть ориентированы на соответствующие товары. Вместе с тем такая группа немногочисленная, поэтому может совершать редко покупки и, соответственно, приносить в общем объеме незначительную прибыль.

Возрастная группа после 35 лет представлена существенно большим количеством покупателей. Несмотря на покупку более низких по цене товаров, она может приносить в разы большую прибыль магазину. Предлагается выбрать в качестве основной целевой аудитории именно ее.

Для уточнения полученного разбиения и подтверждения полученных выводов, необходимо дополнительно проанализировать прибыль, которую получает магазин в данной разбивке.

Модель склонности клиента города 1188 к покупке

Моделирование.

В качестве таргета выберем количество покупок каждого клиента. При этом будем считать, что клиент склонен к покупке, если его количество покупок больше или равно медианному значению количества покупок по всему датафрейме, в противном случае – он не склонен.

Для построения модели выберем следующие данные: пол, возраст, образование, средняя стоимость товара при покупке, товар куплен со скидкой или нет, персональный коэффициент. В итоговый датафрейм было включено 12 438 строк.

Разобьем датафрейм на тренировочную и тестовую выборки с помощью train_test_split. В тестовую выборку отправим 20% датафрейма.

Построим 3 модели: логистическую модель, модель на основе деревьев и модель случайного леса – и выберем лучшую.

Анализ результатов.

По итогу получились следующие результаты.

Логистическая модель

```
Обычный прогноз: MSE = 0.19, MAE = 0.44
Итоги при кросс-валидации: MSE = 0.2, MAE = 0.45
ROC AUC: 0.5211200418687725
Classification Report:
              precision    recall  f1-score   support

           0       0.51      0.19      0.28      1121
           1       0.56      0.85      0.68      1367

    accuracy                           0.55      2488
   macro avg       0.54      0.52      0.48      2488
weighted avg       0.54      0.55      0.50      2488

Confusion Matrix:
 [[ 213  908]
 [ 202 1165]]
```

Модель на основе деревьев

```
Обычный прогноз: MSE = 0.22, MAE = 0.47
Итоги при кросс-валидации: MSE = 0.21, MAE = 0.46
Кросс-валидация при заданной глубине: MSE = 0.19, MAE = 0.44
ROC AUC: 0.5372371700207581
Classification Report:
              precision    recall  f1-score   support

           0       0.52      0.31      0.39      1121
           1       0.57      0.76      0.66      1367

    accuracy                           0.56      2488
   macro avg       0.55      0.54      0.52      2488
weighted avg       0.55      0.56      0.54      2488

Confusion Matrix:
 [[ 350  771]
 [ 325 1042]]
```

Случайный лес

```
Обычный прогноз: MSE = 0.22, MAE = 0.47
Итоги при кросс-валидации: MSE = 0.21, MAE = 0.46
Кросс-валидация при заданной глубине: MSE = 0.19, MAE = 0.44
ROC AUC: 0.5950625388685904
Classification Report:
              precision    recall  f1-score   support

           0       0.54      0.21      0.30      1121
           1       0.57      0.85      0.68      1367

    accuracy                           0.56      2488
   macro avg       0.55      0.53      0.49      2488
weighted avg       0.55      0.56      0.51      2488

Confusion Matrix:
 [[ 230  891]
 [ 199 1168]]
```

Выберем в качестве модели для построения склонности клиента к покупке модель случайного леса. ROC AUC у данной модели наилучший, количество ошибок первого и второго рода наименьшее. Остальные характеристики у всех трех моделей приблизительно одинаковые.

Посмотрим на степень важности каждого признака модели.

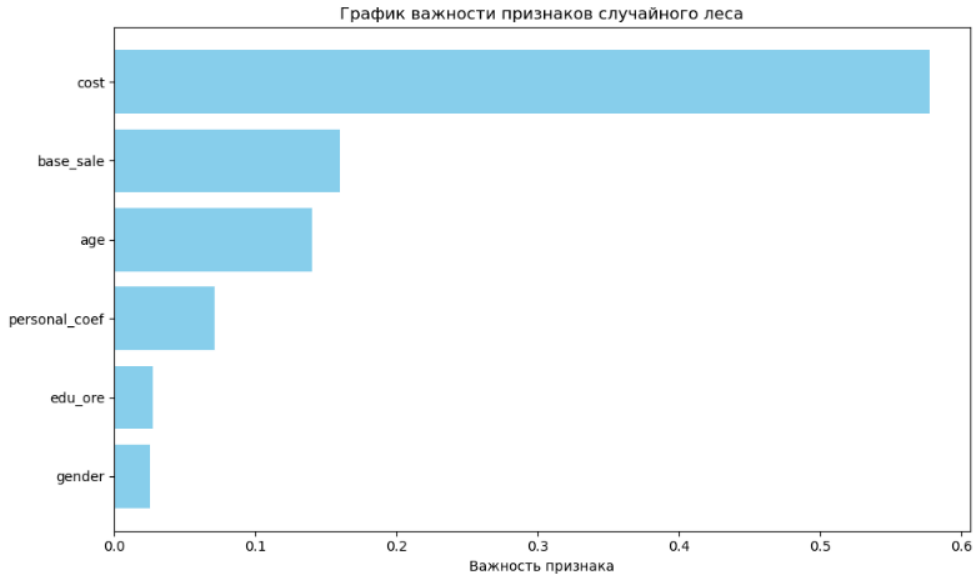

Получается, что самое значительное влияние на склонность клиента к покупке влияет стоимость товара, практически одинаково влияют наличие скидки и возраст клиента. Пол клиента и образование оказывают наименьшее влияние на решение покупателя о совершении покупки.

Рекомендации по улучшению модели.

В качестве улучшения модели можно рассмотреть добавление других признаков, которые потенциально могут влиять на модель. Например, вид товара. Однако перед тем, как добавить этот фактор, нужно обязательно провести обработку наименования товаров, чтобы одинаковые позиции были идентичны. Возможно, вместо вида товара стоит использовать категорию (например, «женские товары», «верхняя одежда» и т.д). В данном случае существенную роль играет определение категорий товаров: на сколько крупными они должны быть, необходимо ли деление на гендерную часть.

Также в модель можно добавить еще больше информации о покупателях (при возможности их получить). Например, семейное положение, наличие детей, работает клиент или нет.

Заключение.

Заказчиком были предоставлены достаточно полные данные, что позволило провести полноценный анализ, без существенных предположений и допущений (необходимо было восстановить только пол части клиентов).

Итогами проведенной маркетинговой кампании стал вывод о том, что существенного роста покупок со стороны клиентов не произошло, а значит, предоставление персональной скидки по средствам email-рассылки не является эффективной. *Рекомендации*: провести маркетинговую кампанию с использованием других способов предоставления персональной скидки (sms-рассылка, рассылка в месенджерах, флайеры на скидку при непосредственной покупке). Рассмотреть другие способы привлечения клиентов, например, провести коллаборацию с другим магазином/рестораном/спортивным комплексом.

Разбиение на кластеры выявило незначительную часть покупателей, совершающих дорогие покупки, а также показало, что большая часть клиентов делает недорогие покупки. *Рекомендации*: провести дополнительный анализ (предоставить дополнительные данные), который показал бы долю прибыли каждого кластера в общем объеме.

Было построено 3 модели, предсказывающие склонность покупателя к покупке. Лучшей оказалась модель случайного леса. Основным фактором влияния оказалась стоимость товара. *Рекомендации*: при возможности получения дополнительной информации о клиенте, можно попробовать улучшить показатели модели.